

Projet — Analyse de la Polarisation

Nom 1

Nom 2

Nom 3

17 mars 2026

Table des matières

1	Introduction	2
2	Description générale de l'implémentation	2
3	Question 1 — Génération aléatoire de profils d'approbation	2
4	Question 2 — Génération aléatoire de profils par ordres totaux	3
5	Question 4 — Quels axiomes sont satisfaits par ϕ_2 ?	3
6	Question 6 — Expériences sur ϕ_2	5
6.1	Cas approval	5
6.2	Cas ranking	6
7	Question 7 — Montrer que d_H et d_S sont des distances	6
8	Question 9 — Quels axiomes sont satisfaits par ϕ_{d_H} et ϕ_{d_S} ?	7
9	Question 10 — Calcul efficace de u_1 pour les votes par approbation	9
10	Question 11 — Calcul efficace de u_1 pour les ordres totaux	9
11	Question 15 — Expériences sur ϕ_{d_H} et ϕ_{d_S}	10
11.1	Cas approval : ϕ_{d_H}	10
11.2	Cas ranking : ϕ_{d_S}	11
12	Utilisation des IA génératives	11
13	Sources	12
14	Conclusion	12

1 Introduction

Dans ce projet, nous étudions plusieurs manières de mesurer la polarisation d'un profil électoral. L'idée générale est de comparer des profils peu polarisés, où les votantes restent proches d'un même centre, à des profils fortement polarisés, où l'électorat se sépare en deux blocs opposés.

Le sujet considère deux cadres :

- les votes par approbation ;
- les votes par ordres totaux.

Notre travail a consisté à :

- générer des profils aléatoires avec un niveau de polarisation contrôlable ;
- implémenter plusieurs mesures de polarisation ;
- analyser certaines propriétés axiomatiques ;
- produire des expériences pour visualiser l'évolution de ces mesures.

Dans toute la suite, on note n le nombre de votantes et m le nombre de candidates.

2 Description générale de l'implémentation

Le code du projet est organisé autour des modules suivants :

- `src/generation.py` : génération des profils ;
- `src/distances.py` : distances de Hamming et de Spearman ;
- `src/pairwise.py` : quantités $d^{ck,cl}(p)$;
- `src/phi2.py` : calcul de ϕ_2 ;
- `src/consensus.py` : calcul du consensus global u_1 ;
- `src/clustering.py` : approximation à deux groupes $\widetilde{u_2}$;
- `src/measures.py` : calcul de ϕ_{dH} et ϕ_{dS} ;
- `src/experiments.py` et `src/plots.py` : expériences et graphiques.

Toutes les expériences finales ont été générées avec le pipeline :

```
python -m scripts.run_final_pipeline
```

3 Question 1 — Génération aléatoire de profils d'approbation

Pour les votes par approbation, nous avons retenu une génération à partir :

- d'un bulletin central a ;
- de son bulletin opposé $\bar{a}$;
- d'un paramètre $\alpha \in [0, 1]$ qui contrôle le niveau de polarisation ;
- d'un paramètre de bruit `noise`.

Le principe est le suivant :

- si α est proche de 0, la majorité des votantes restent proches d'un même centre ;
- si α est proche de 1, le profil se rapproche d'une répartition en deux blocs opposés ;
- le bruit permet d'éviter d'obtenir des profils trop artificiels.

Cette méthode est implémentée dans `generate_approval_profile(n, m, alpha, noise, seed)`.

Justification du choix Ce schéma a l'avantage d'être simple à paramétrer, facile à expliquer, et surtout compatible avec l'intuition demandée dans le sujet : faible polarisation autour d'un centre unique, forte polarisation autour de deux pôles opposés.

Exemple Si $m = 4$ et que le centre vaut $a = (1, 0, 1, 0)$, alors :

— pour une faible polarisation, on peut obtenir un profil du type

$$(1, 0, 1, 0), (1, 0, 1, 0), (1, 0, 0, 0), (1, 0, 1, 1),$$

c'est-à-dire des bulletins proches du centre ;

— pour une forte polarisation, on peut au contraire obtenir un profil de la forme

$$(1, 0, 1, 0), (1, 0, 1, 0), (0, 1, 0, 1), (0, 1, 0, 1),$$

qui se rapproche de deux blocs opposés.

4 Question 2 — Génération aléatoire de profils par ordres totaux

Pour les votes par ordres totaux, nous avons utilisé une méthode analogue :

- on tire un ordre central σ ;
- on considère son ordre inverse comme pôle opposé ;
- le paramètre α détermine la proportion de votantes proches de chaque pôle ;
- un bruit est ajouté sous la forme d'un nombre contrôlé d'échanges aléatoires dans le classement.

Cette méthode est implémentée dans `generate_ranking_profile(n, m, alpha, noise, seed)`.

Justification du choix Le recours à l'ordre inverse comme second pôle est naturel, car il fournit une opposition forte et simple à interpréter. Le bruit par échanges permet d'obtenir des profils plus réalistes sans casser la logique globale de polarisation.

Exemple Si $m = 4$ et que l'ordre central est (c_1, c_2, c_3, c_4) , alors :

— pour une faible polarisation, un profil typique ressemble à

$$(c_1, c_2, c_3, c_4), (c_1, c_3, c_2, c_4), (c_1, c_2, c_4, c_3),$$

où les classements restent proches les uns des autres ;

— pour une forte polarisation, on se rapproche plutôt de deux blocs opposés, par exemple

$$(c_1, c_2, c_3, c_4), (c_1, c_2, c_3, c_4), (c_4, c_3, c_2, c_1), (c_4, c_3, c_2, c_1).$$

5 Question 4 — Quels axiomes sont satisfaits par ϕ_2 ?

Nous rappelons que le sujet définit :

$$\phi_2(p) = \sum_{\{c_k, c_l\} \in C^2} \frac{n - d^{c_k, c_l}(p)}{n \binom{m}{2}},$$

avec

$$d^{c_k, c_l}(p) = |n_{c_k c_l}(p) - n_{c_l c_k}(p)|.$$

Discussion générale

Notre implémentation suit cette définition dans `src/pairwise.py` et `src/phi2.py`. Les expériences montrent que la mesure croît globalement lorsque le niveau de polarisation augmente.

Régularité

On a toujours $0 \leq d^{c_k, c_l}(p) \leq n$, donc

$$0 \leq \frac{n - d^{c_k, c_l}(p)}{n \binom{m}{2}} \leq \frac{1}{\binom{m}{2}}.$$

En sommant sur toutes les paires, on obtient bien

$$0 \leq \phi_2(p) \leq 1.$$

En revanche, la partie forte de l'axiome de régularité n'est pas satisfaite dans toute sa forme.

Pourquoi $\phi_2(p) = 0$ n'est pas équivalent à un profil de la forme p_a dans le cas approval

Considérons le profil homogène où toutes les votantes ont le bulletin $(1, 1)$. Pour l'unique paire $\{c_1, c_2\}$, on a

$$n_{c_1 c_2}(p) = 0, \quad n_{c_2 c_1}(p) = 0,$$

donc $d^{c_1, c_2}(p) = 0$, et ainsi $\phi_2(p) = 1$. Pourtant, le profil est parfaitement homogène. La caractérisation $\phi_2(p) = 0 \Leftrightarrow p = p_a$ n'est donc pas vraie en général dans le cadre approval.

Pourquoi $\phi_2(p) = 1$ n'est pas forcément équivalent à un profil exactement bipolaire

Dans le cas ranking, on peut construire des profils où chaque paire de candidates est partagée équitablement sans que le profil soit exactement de la forme $p_{\sigma, \bar{\sigma}}$. La valeur 1 traduit donc surtout un équilibre parfait au niveau paire à paire, pas nécessairement une structure strictement bipolaire unique.

Ainsi, ϕ_2 vérifie bien la borne $[0, 1]$, mais pas la caractérisation forte demandée par l'axiome 1.

Neutralité

La mesure est neutre. En effet, si l'on permute les candidates par une permutation π , chaque paire $\{c_k, c_l\}$ est simplement renommée en $\{\pi(c_k), \pi(c_l)\}$. Les nombres $n_{c_k c_l}(p)$ et $n_{c_l c_k}(p)$ sont donc eux aussi seulement renommés, sans changer leurs valeurs. L'ensemble des termes de la somme définissant ϕ_2 reste inchangé. Par conséquent,

$$\phi_2(p) = \phi_2(p^\pi).$$

Anonymat

La mesure est anonyme. En effet, permuter les votantes ne change pas le nombre de votantes qui préfèrent c_k à c_l , ni celui des votantes qui préfèrent c_l à c_k . Les quantités $n_{c_k c_l}(p)$, $d^{c_k, c_l}(p)$ et donc $\phi_2(p)$ restent inchangées. Ainsi,

$$\phi_2(p) = \phi_2(fp)$$

pour toute permutation f des votantes.

Invariance par réplication

La mesure est invariante par réplication. Si l'on remplace le profil p par kp , alors tous les effectifs $n_{c_k c_l}(p)$ sont multipliés par k . On a donc

$$n_{c_k c_l}(kp) = k n_{c_k c_l}(p), \quad d^{c_k, c_l}(kp) = k d^{c_k, c_l}(p),$$

et le nombre total de votantes devient kn . Pour chaque paire,

$$\frac{kn - k d^{c_k, c_l}(p)}{kn \binom{m}{2}} = \frac{n - d^{c_k, c_l}(p)}{n \binom{m}{2}}.$$

La somme totale est donc inchangée, ce qui donne

$$\phi_2(kp) = \phi_2(p).$$

Conclusion pour la question 4 La mesure ϕ_2 vérifie :

- la borne $0 \leq \phi_2 \leq 1$;
- la neutralité ;
- l'anonymat ;
- l'invariance par réplication.

En revanche, la version forte de la régularité, avec caractérisation exacte des cas $\phi_2 = 0$ et $\phi_2 = 1$, n'est pas satisfaite en général.

6 Question 6 — Expériences sur ϕ_2

Pour cette question, nous avons fait varier le paramètre de polarisation α entre 0 et 1 par pas de 0.1, avec :

- $n = 40$ votantes ;
- $m = 6$ candidates ;
- 20 essais par valeur de α pour ϕ_2 .

6.1 Cas approval




FIGURE 1 – Évolution de ϕ_2 pour les profils approval.

On observe une augmentation nette de la mesure lorsque α augmente. La moyenne passe d'environ 0.571 pour $\alpha = 0$ à environ 0.951 pour $\alpha = 1$. Cela est cohérent avec l'idée que la mesure détecte correctement le passage d'un profil peu polarisé à un profil fortement bipolaire.

6.2 Cas ranking




FIGURE 2 – Évolution de ϕ_2 pour les profils ranking.

Le comportement est similaire : la moyenne augmente d'environ 0.500 à 0.881. La croissance est régulière et confirme que la génération retenue pour les profils ranking produit bien des instances de plus en plus polarisées lorsque α croît.

Conclusion expérimentale Dans les deux cadres, ϕ_2 réagit dans le sens attendu au paramètre de polarisation. Cela valide à la fois la méthode de génération et l'implémentation de la mesure.

7 Question 7 — Montrer que d_H et d_S sont des distances

Les deux distances utilisées dans le projet sont :

- la distance de Hamming sur les votes par approbation ;
- la distance de Spearman sur les ordres totaux.

Plan de rédaction conseillé

Pour d_H Soient $a, b, c \in \{0, 1\}^m$.

- *Positivité* : chaque terme $1_{a[i] \neq b[i]}$ vaut 0 ou 1, donc

$$d_H(a, b) = \sum_{i=1}^m 1_{a[i] \neq b[i]} \geq 0.$$

- *Séparation* : $d_H(a, b) = 0$ si et seulement si aucun indice ne diffère, donc si et seulement si $a = b$.

— *Symétrie* : la condition $a[i] \neq b[i]$ est équivalente à $b[i] \neq a[i]$, donc

$$d_H(a, b) = d_H(b, a).$$

— *Inégalité triangulaire* : si $a[i] \neq c[i]$, alors au moins l'un des deux événements $a[i] \neq b[i]$ ou $b[i] \neq c[i]$ est vrai. Ainsi,

$$1_{a[i] \neq c[i]} \leq 1_{a[i] \neq b[i]} + 1_{b[i] \neq c[i]}.$$

En sommant sur tous les indices i , on obtient

$$d_H(a, c) \leq d_H(a, b) + d_H(b, c).$$

Ainsi, d_H est bien une distance.

Pour d_S Soient σ, τ, ρ trois ordres totaux sur C , et r_σ, r_τ, r_ρ les fonctions de rang associées.

— *Positivité* :

$$d_S(\sigma, \tau) = \sum_{c \in C} |r_\sigma(c) - r_\tau(c)| \geq 0.$$

— *Séparation* : si $d_S(\sigma, \tau) = 0$, alors pour toute candidate c ,

$$|r_\sigma(c) - r_\tau(c)| = 0,$$

donc $r_\sigma(c) = r_\tau(c)$. Les deux ordres sont donc identiques.

— *Symétrie* : pour toute candidate c ,

$$|r_\sigma(c) - r_\tau(c)| = |r_\tau(c) - r_\sigma(c)|,$$

donc $d_S(\sigma, \tau) = d_S(\tau, \sigma)$.

— *Inégalité triangulaire* : pour chaque candidate c , l'inégalité triangulaire sur $\mathbb{R}$ donne

$$|r_\sigma(c) - r_\rho(c)| \leq |r_\sigma(c) - r_\tau(c)| + |r_\tau(c) - r_\rho(c)|.$$

En sommant sur toutes les candidates,

$$d_S(\sigma, \rho) \leq d_S(\sigma, \tau) + d_S(\tau, \rho).$$

Ainsi, d_S est bien une distance.

Appui algorithmique Ces deux fonctions sont implémentées dans `src/distances.py` sous les noms :

— `hamming_distance(a, b)`

— `spearman_distance(order1, order2)`

Le code ne remplace pas les preuves, mais il a permis de valider des cas tests simples.

8 Question 9 — Quels axiomes sont satisfaits par ϕ_{d_H} et ϕ_{d_S} ?

Les mesures utilisées sont :

$$\phi_{d_H}(p) = \frac{2}{nm} (u_1(p) - \widetilde{u}_2(p))$$

et

$$\phi_{d_S}(p) = \frac{4}{nm^2} (u_1(p) - \widetilde{u}_2(p)).$$

Commentaires

Ces mesures comparent :

- le coût d'un consensus global unique ;
- le coût d'une partition en deux groupes avec deux centroïdes.

Intuitivement, plus l'électorat se sépare en deux blocs, plus le gain apporté par deux centroïdes devient important.

Neutralité

Si l'on raisonne sur la version idéale de la mesure, où u_2 est la vraie valeur optimale du problème à deux centroïdes, alors la neutralité est vérifiée. Une permutation des candidates ne change pas les distances entre bulletins : elle ne fait que renommer les candidates. Les valeurs u_1 et u_2 sont donc inchangées, et la mesure aussi.

Anonymat

La mesure est anonyme. En effet, u_1 et u_2 ne dépendent que de l'ensemble des bulletins présents, pas de l'ordre dans lequel ils sont listés. Une permutation des votantes ne change donc ni u_1 , ni u_2 , ni la valeur finale de la mesure.

Invariance par réplication

Si l'on remplace p par kp , alors tous les coûts de distance sont multipliés par k :

$$u_1(kp) = k u_1(p), \quad u_2(kp) = k u_2(p).$$

Le facteur k est alors compensé par le nouveau nombre de votantes kn dans le facteur de normalisation. On obtient donc

$$\phi_{d_H}(kp) = \phi_{d_H}(p)$$

et de même pour ϕ_{d_S} .

Régularité

On a toujours $u_2(p) \leq u_1(p)$, donc les mesures sont toujours positives ou nulles. De plus, dans les profils unanimistes, on a $u_1 = u_2 = 0$, donc la mesure vaut 0.

Pour les profils parfaitement bipolaires, le consensus à deux centroïdes devient beaucoup plus performant que le consensus global, et la mesure devient grande. Dans le cas approval, le profil $p_{a,\bar{a}}$ donne bien la valeur 1 pour la version idéale de ϕ_{d_H} .

En revanche, la caractérisation exacte de tous les cas d'égalité à 1 est plus délicate, en particulier dans le cas ranking. En pratique, nos expériences montrent que la mesure reste bien dans $[0, 1]$, mais la preuve générale complète des cas extrêmes demanderait une étude plus poussée.

Conclusion pour la question 9 Les mesures basées sur les distances vérifient clairement :

- l'anonymat ;
- la neutralité ;
- l'invariance par réplication ;
- la nullité sur les profils unanimistes.

La discussion des cas extrêmes de régularité est plus simple dans le cadre approval que dans le cadre ranking.

9 Question 10 — Calcul efficace de u_1 pour les votes par approbation

Dans le cas des votes par approbation, le problème consiste à trouver un bulletin $a \in \{0, 1\}^m$ qui minimise

$$\sum_{a' \in p} d_H(a, a').$$

Idée

La distance de Hamming se séparant coordonnée par coordonnée, il suffit de traiter chaque candidate indépendamment :

- si une majorité de votantes approuvent la candidate, le consensus met 1 ;
- sinon, le consensus met 0.

Ainsi, le bulletin de consensus est obtenu par vote majoritaire sur chaque composante.

Implémentation

Cette idée est implémentée dans :

- `approval_consensus_ballot(profile)`
- `u1_approval(profile)`

Conclusion Le calcul est efficace car il se ramène à compter, pour chaque position, le nombre de 1 et de 0.

10 Question 11 — Calcul efficace de u_1 pour les ordres totaux

Dans le cas des ordres totaux, on cherche un ordre de consensus minimisant la somme des distances de Spearman à tous les votes du profil.

Idée de modélisation

On peut voir ce problème comme une affectation des candidates aux positions finales du classement. Pour chaque candidate c et chaque position r , on calcule le coût :

$$\sum_{v \in V} |r_v(c) - r|.$$

On obtient ainsi une matrice de coûts *candidate* $\times$ *position*. Le problème revient ensuite à choisir une affectation bijective minimisant la somme totale, ce qui correspond à un problème de couplage parfait de poids minimum dans un graphe biparti.

Implémentation retenue

Dans notre code, cette idée est implémentée par programmation dynamique sur les sous-ensembles :

- `ranking_assignment_costs(profile)` construit la matrice de coûts ;
- `ranking_consensus_ballot(profile)` cherche l'affectation optimale ;
- `u1_ranking(profile)` calcule ensuite le coût total du consensus obtenu.

Remarque Cette solution est exacte et suffit pour les tailles de m utilisées dans nos expériences. Elle suit bien l'esprit de l'indication du sujet, même si l'on n'utilise pas directement `scipy`.

Complexité Si m est le nombre de candidates, la programmation dynamique explore les sous-ensembles de candidates déjà placées. Le nombre d'états est donc de l'ordre de $m2^m$, ce qui reste raisonnable pour les valeurs modestes de m utilisées dans nos expériences, mais ne serait pas adapté à des instances très grandes.

11 Question 15 — Expériences sur ϕ_{d_H} et ϕ_{d_S}

Pour cette question, nous avons utilisé le même protocole global sur $\alpha \in \{0, 0.1, \dots, 1\}$, avec :

- $n = 40$,
- $m = 6$,
- 10 essais par valeur de α ,
- 10 relances pour l'algorithme de clustering à deux groupes.

11.1 Cas approval : ϕ_{d_H}




FIGURE 3 – Évolution de ϕ_{d_H} pour les profils approval.

La courbe est fortement croissante. La moyenne passe d'environ 0.055 à 0.715, ce qui montre que plus le profil est polarisé, plus un consensus à deux blocs devient meilleur qu'un consensus global unique.

11.2 Cas ranking : ϕ_{d_S}




FIGURE 4 – Évolution de ϕ_{d_S} pour les profils ranking.

La moyenne passe d'environ 0.125 à 0.501. La tendance est globalement croissante. La partie finale de la courbe reste un peu plus bruitée que dans le cas approval, mais le signal reste cohérent avec l'intuition de polarisation.

Interprétation Ces résultats montrent que les mesures basées sur les distances détectent elles aussi l'augmentation du niveau de polarisation. Elles complètent utilement ϕ_2 , qui repose davantage sur l'analyse paire à paire des préférences.

12 Utilisation des IA génératives

Nous avons utilisé des IA génératives principalement comme outils d'assistance technique et rédactionnelle. Les usages principaux ont été :

- proposer une structure de projet en Python ;
- générer une première version de certaines fonctions ;
- ajouter des commentaires de code ;
- aider à structurer les rapports intermédiaires et le rapport final ;
- aider au débogage de l'environnement et à l'automatisation des expériences.

Le nombre exact de prompts n'a pas été compté à l'unité, mais il s'agit d'un usage régulier tout au long du projet, avec plusieurs dizaines d'interactions courtes ou moyennes.

Apports utiles

- L'IA a permis d'accélérer fortement la mise en place du squelette du projet.
- Elle a été utile pour organiser le code, proposer des interfaces de fonctions et rédiger des commentaires.
- Elle a aussi permis de gagner du temps sur les scripts expérimentaux et sur la structuration des rapports intermédiaires.

Limites observées

- Certaines propositions initiales n'étaient pas exactement alignées avec le PDF.
- En particulier, la première version de ϕ_2 et de $d^{c_k, c_l}(p)$ a dû être corrigée manuellement après relecture du sujet.
- L'IA est donc utile pour accélérer le travail, mais elle ne remplace pas la vérification mathématique ni la validation expérimentale.

Bilan critique L'utilisation de l'IA a été globalement positive, surtout pour l'organisation du projet et l'accélération du développement. En revanche, elle n'a pas dispensé d'une lecture attentive du sujet ni de la validation manuelle des définitions. Son principal risque est de donner trop vite une solution apparemment cohérente mais mathématiquement imprécise.

13 Sources

- Sujet du projet : *Projet : Analyse de la Polarisation*, L3 Info 2025–2026, Fondements Mathématiques pour l'Aide à la Décision.
- Documentation Python standard, pour l'utilisation des structures de données et des modules standards.
- Documentation de `matplotlib`, pour la production des figures expérimentales.
- Documentation de `pytest`, pour la mise en place des tests unitaires.

14 Conclusion

Le projet permet maintenant :

- de générer des profils plus ou moins polarisés ;
- de calculer plusieurs mesures de polarisation ;
- de comparer leur comportement par expérience ;
- de produire les figures nécessaires au rapport.

Les résultats obtenus montrent de manière cohérente que les mesures considérées augmentent lorsque le paramètre de polarisation α augmente. Il reste à finaliser la partie théorique, notamment les preuves des propriétés axiomatiques, et à mettre au propre les dernières parties rédactionnelles.